

Лекция 1. Методология CRISP-DM. Начало работы над ML-проектом

Практикум по программированию, 5 семестр

Иван Евгеньевич Бугаенко,
ассистент каф. ПМИФИ

Цель курса

Основная цель – научиться работать с ML-проектами и строить обоснованные модели на основе аналитики данных

- принятие решений на основе статистического и графического анализа данных и аргументация своих действий
- обоснование выбора методов предобработки данных и моделей для прогнозирования
- интерпретирование работы модели
- применение современных методов анализа данных и лучших практик

Формат работы

Курс состоит из:

- 5+4 лекционных занятий (10 баллов)
- 5 лабораторных работ (50 баллов)
- домашнего задания (10 баллов)
- демозамена (30 баллов)

Итого: 100 баллов


Все материалы выкладываются на wiki.pmifi.ru

Рейтинг ведется в [таблице](#)

Зачем нужно обосновывать свои
решения в ML?


Итоговая цель каждого ML-проекта –
разработать жизнеспособную модель

Как вы себе представляете работу над ML-проектом?




натыкать наугад

Как вы себе представляете работу над ML-проектом?




натыкать наугад




перебрать все
варианты

Как вы себе представляете работу над ML-проектом?



натыкать наугад



перебрать все
варианты



обоснованный пайплайн
работы с данными

Проблемы других подходов

- невозможно перебрать ВСЕ варианты
- шаги по работе с данными могут совершаться интуитивно и наугад, что может испортить качество модели
- нет обоснования, почему были совершены те или иные действия, что затрудняет читаемость работы и ее воспроизводимость

Проблемы других подходов

- невозможно перебрать ВСЕ варианты
- шаги по работе с данными могут совершаться интуитивно и наугад, что может испортить качество модели
- нет обоснования, почему были совершены те или иные действия, что затрудняет читаемость работы и ее воспроизводимость

**Работа становится одним большим черным ящиком!
Итоговой модели нельзя доверять**

Что такое аналитика данных?

Аналитика данных – это набор подходов и инструментов по извлечению информации из данных, которая используется для обоснования шагов, которые совершаются в ходе решения ML-задачи


Обосновывая свои шаги, исследователь
получает жизнеспособную, надежную и
понимаемую модель

Жизненный цикл ML-проекта

CRISP-DM (Cross-Industry Standard Process for Data Mining) – это стандартная методология жизненного цикла проектов по анализу данных и машинному обучению, которая описывает последовательность шагов от постановки бизнес-задачи до внедрения готового решения

Этапы CRISP-DM

Business Understanding	Data Understanding	Data Preparation	Modeling	Evaluation	Deployment
Determine Business Objectives <i>Background Business Objectives Business Success Criteria</i>	Collect Initial Data <i>Initial Data Collection Report</i>	Select Data <i>Rationale for Inclusion/ Exclusion</i>	Select Modeling Techniques <i>Modeling Technique Modeling Assumptions</i>	Evaluate Results <i>Assessment of Data Mining Results w.r.t. Business Success Criteria Approved Models</i>	Plan Deployment <i>Deployment Plan</i>
Assess Situation <i>Inventory of Resources Requirements, Assumptions, and Constraints Risks and Contingencies Terminology Costs and Benefits</i>	Describe Data <i>Data Description Report</i>	Clean Data <i>Data Cleaning Report</i>	Generate Test Design <i>Test Design</i>	Review Process <i>Review of Process</i>	Plan Monitoring and Maintenance <i>Monitoring and Maintenance Plan</i>
Determine Data Mining Goals <i>Data Mining Goals Data Mining Success Criteria</i>	Explore Data <i>Data Exploration Report</i>	Construct Data <i>Derived Attributes Generated Records</i>	Build Model <i>Parameter Settings Models Model Descriptions</i>	Determine Next Steps <i>List of Possible Actions Decision</i>	Produce Final Report <i>Final Report Final Presentation</i>
Produce Project Plan <i>Project Plan Initial Assessment of Tools and Techniques</i>	Verify Data Quality <i>Data Quality Report</i>	Integrate Data <i>Merged Data</i>	Assess Model <i>Model Assessment Revised Parameter Settings</i>	Review Project <i>Experience Documentation</i>	
		Format Data <i>Reformatted Data</i>			
		<i>Dataset Dataset Description</i>			



Можно ли шаблонизировать ML-
проект?

Каждая ML-задача уникальна, однако можно выделить базовый пайплайн по обработке данных с учетом CRISP-DM

Основные шаги по работе с ML-проектом

0. Описание задачи и признаков (Business & Data Understanding)
1. Предварительная обработка данных (Data Preparation)
2. Генерация новых признаков (Data Preparation)
3. Выбор ML-моделей и метрик качества (Modeling)
4. Обучение моделей, кросс-валидация и подбор гиперпараметров (Modeling)
5. Получение предсказаний на новых данных и вычисление метрик (Evaluation)

Шаг 0. Описание задачи и признаков

На данном шаге исследователь собирает всю входную информацию о проекте:

- формулирует постановку задачи
- выполняет описание признакового пространства (определяет входные и целевые признаки, ограничения на значения, выписывает зависимости прикладной области)
- формирует виртуальное окружение (импорт библиотек, seed, фиксация версий библиотек для работы)
- + в самом конце – содержание работы (table of content)

Цель: сделать так, чтобы читатель понял, для чего решается задача, какая это вообще задача, а также чтобы работа была воспроизводима (можно было ее запустить с теми же параметрами)

Шаг 1. Предварительная обработка данных

На данном шаге исследователь выполняет базовые действия по работе с данными:

- загружает данные в рабочее пространство, выводит их и приводит признаки к необходимому типу (+ агрегация, парсинг дат, отбрасывание столбцов) – первичный этап обработки данных
- разделяет выборку на обучение и тест
- обрабатывает пропущенные значения
- выполняет кодировку категориальных признаков
- решает проблему наличия выбросов и аномалий в данных
- устраняет дисбаланс классов (для задачи классификации)

Цель: обработать данные так, чтобы можно было обучить baseline-модель

Baseline-модель – это такая наивная модель ML, которая обучалась на базовом варианте обработанных данных. Используется для проверки эффективности инструментов предобработки

Советы по начальному этапу обработки датасета

- всегда обращайте внимание на кодировку файла с данными и на разделитель (если речь про .csv и .tsv файлы)
- если датасет содержит даты, то передавайте их в параметр `parse_dates`
- обязательно выводите фрагмент датасета через `DataFrame.head()`, чтобы убедиться, что все корректно почиталось
- анализируйте при помощи `DataFrame.info()`, корректно ли парсятся типы данных при загрузке датасета (сверяйтесь с табличкой, содержащей инфу о семантике признаков); если типы не соответствуют, выполняйте ручное приведение
- для принятия решения об отбрасывании категориального признака смотрите на его семантику и количество уникальных значений (`Series.nunique()`)
- обращайте внимание на признаки, которые неизвестны на момент получения прогноза, они подлежат удалению

Советы по начальному этапу обработки датасета

- агрегаты данных разбивайте на компоненты, если это не критично для задачи (например, дату можно разбить на день, месяц и год, если не решается задача анализа временных рядов)
- контролируйте, чтобы во входных признаках не было утечки данных

Типичные ошибки при делении выборки на train/test

- допускается утечка информации → рекомендуется сначала выполнять деление выборки, а потом выполнять действия только с train-датасетом (и результаты переносить на test)
- игнорируется временная структура данных → нужно контролировать, чтобы данные о "будущем" не попадали в обучающую выборку
- нарушение баланса классов → использовать стратификацию выборки при разделении (например, поле stratify=...)
- слишком большой/маленький train/test → контролировать объем выборки